TMDB Filmu ieņēmumu Prognozēšana

Krišjānis Oliņš | 2026. gada 22. aprīlis

Kopsavilkums: Prognozējam populārāko filmu ieņēmumus, izmantojot Random Forest regresijas modeli, lai mazinātu filmu studiju finansiālos riskus.

Problēma un Dati

- **Problēma:** Filmu studijām ir grūti paredzēt ieņēmumus pirms filmas izlaišanas, tādēļ rīks, kas balstās uz datiem, varētu ietaupīt miljoniem dolāru un optimizēt mārketinga izmaksas.
- **Dati:** Izmantota *TMDB Top 10 000 Popular Movies* datu kopa no Kaggle platformas. Datu izmērs bija aptuveni 9998 rindas un 28 kolonnas.
- **Tīrīšana:** Pēc datu tīrīšanas (novēršot filmas ar nezināmiem budžetiem un ieņēmumiem, izmetot tukšās kolonnas) analīzei sagatavotas 5497 rindas.
- **Vizualizācija:** Izkliedes grafiks parāda budžeta un ieņēmumu asimetrisko korelāciju.

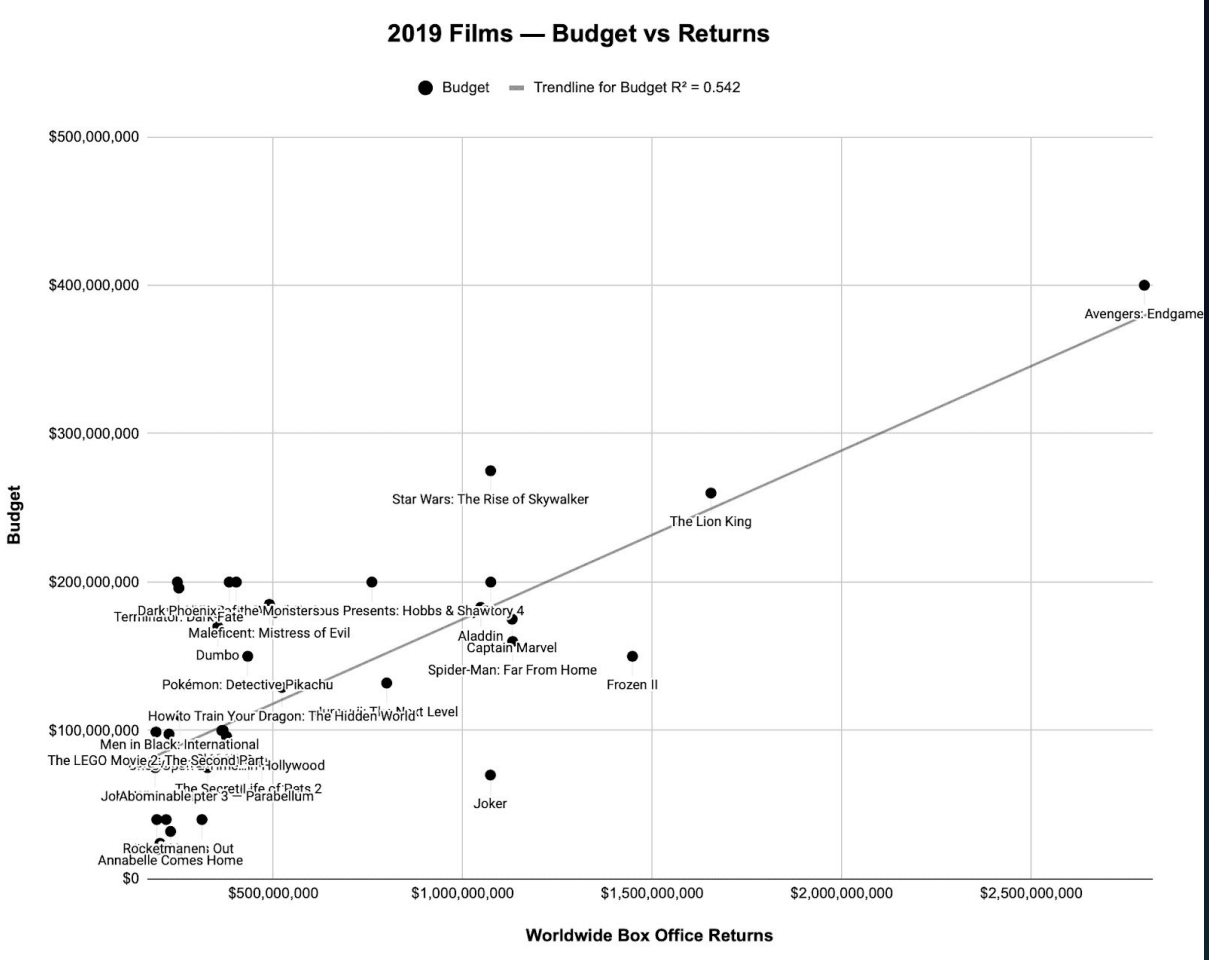

Pieeja un Konveijers (ML Pipeline)

1. ML Tips un Mērķis

Izmantotais mašīnmācīšanās tips ir **Regresija**. Mērķis ir prognozēt nepārtrauktu lielumu – filmas ieņēmumus, tādējādi regresijas modeļi ir vispiemērotākie.

2. Priekšapstrāde

Pielietota logaritmiskā transformācija budžetam un ieņēmumiem. JSON kolonnas apstrādātas un izveidotas jaunas pazīmes: budget_per_minute un popularity_vote_score.

3. Konveijera Struktūra

Skaitliskajiem datiem: SimpleImputer(median) + Scaler.

Kategoriskajiem: SimpleImputer(most_frequent) + OneHotEncoder.

Modeļu Salīdzinājums (R^2 Metrika)

Vizuāls R^2 uzlabojums pārejot no bāzes uz koku modeļiem. Labākie parametri ar GridSearchCV: n_estimators=200, max_depth=None, min_samples_split=2.

Rezultāti un Interpretācija

- **Galvenās Metrikas:** Vidējais krusteniskās validācijas (CV) R^2 rezultāts sasniedza 0.456, izskaidrojot būtisku datu dispersiju.
- **Feature Importance:** Modelis parādīja, ka budget un vote_count ir dominējošie faktori prognozē.
- **Jaunās Pazīmes:** Izveidotās popularity_vote_score un budget_per_minute arī deva nozīmīgu korelāciju.
- **Atlikumu Analīze:** Faktiskie pret prognozētajiem ieņēmumiem parāda, ka modelis labi tver bāzes tendenci.

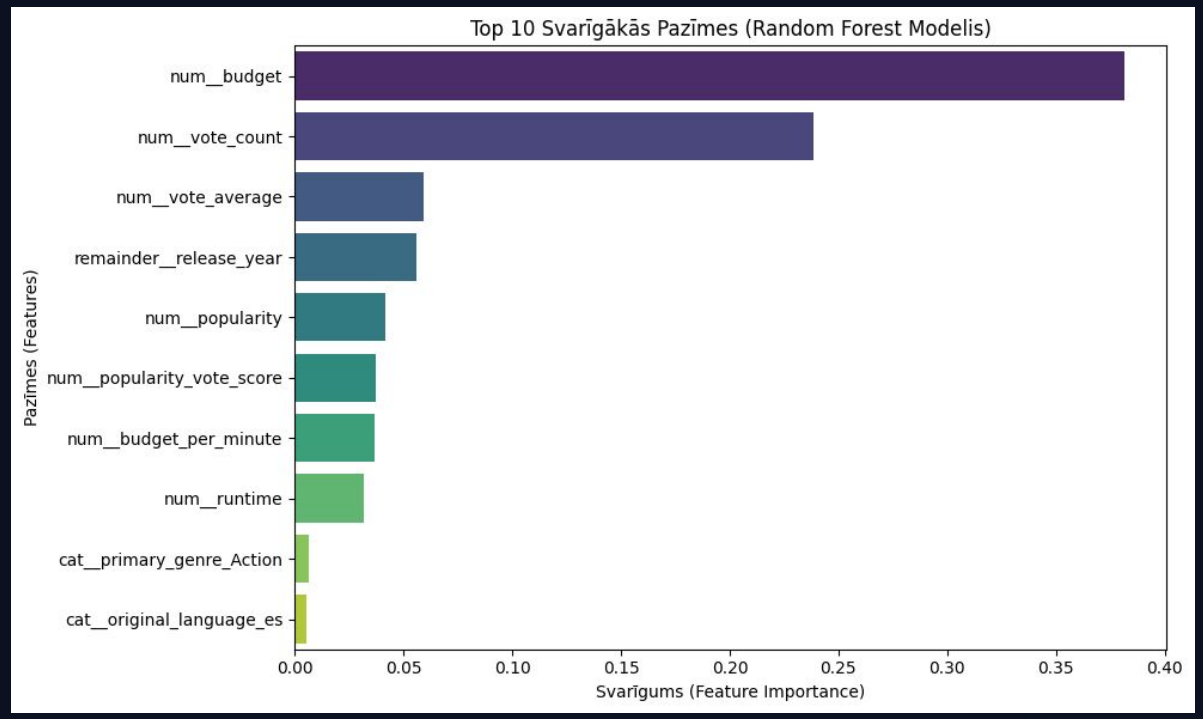

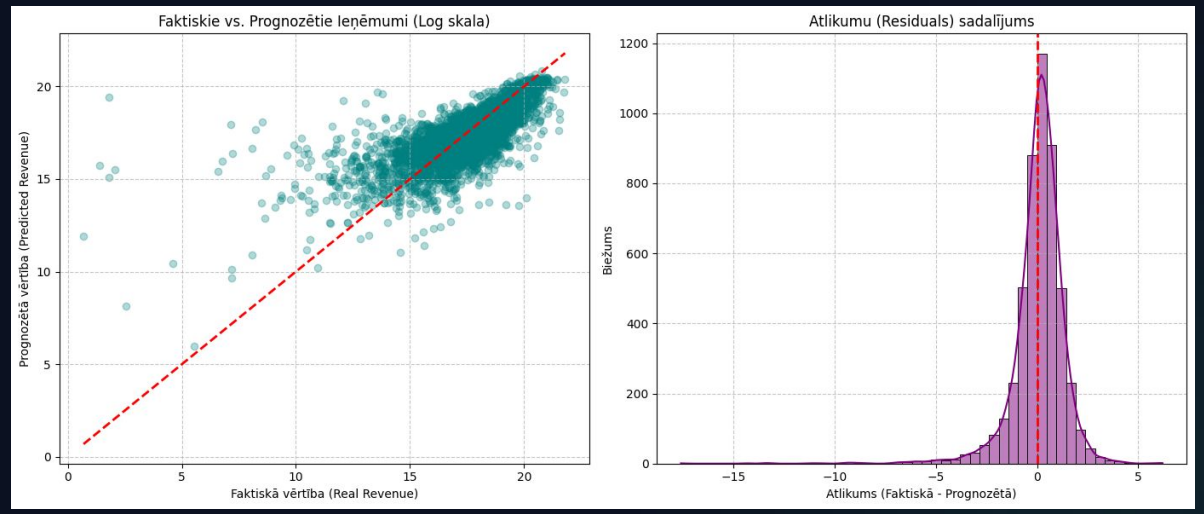

Secinājumi un Nākamie Soļi

Iemācītais no modeļa

Mašīnmācīšanās modeļi lieliski identificē filmu ieņēmumu bāzes tendences, taču tie bieži kļūdās ar "izlēcējiem" (outliers) jeb negaidītiem kases grāvējiem vai finansiālām izgāšanām.

Attīstība un Nākamie Soļi

Nākotnē datus nepieciešams papildināt ar informāciju par aktieru popularitāti, sociālo tīklu sentimentu, kā arī izmantot NLP (Dabiskās valodas apstrādi) filmas sižeta tekstam.

Jautājumi?

Paldies par uzmanību!